Univerzitet u Beogradu — Matematički fakultet

Klasterovanje i pravila pridruživanja na scRNA-seq podacima ljudske jetre

Vuk Vujasinović Bogdan Delić

Beograd, 2025.

Sadržaj

1 Uvod **3**

2 Opis skupa podataka **3**

3 Preprocesiranje podataka **3**
3.1 Selekcija atributa 3
3.2 Standardizacija 4
3.3 Redukcija dimenzionalnosti — PCA 4
3.4 Vizualizacija — UMAP 4

4 Klasterovanje **4**
4.1 Određivanje optimalnog broja klastera 4
4.2 K-Means 5
4.3 Aglomerativno klasterovanje 5
4.4 Bisecting K-Means 5
4.5 DBSCAN 6
4.6 K-Medoids 6

5 Poređenje algoritama **7**
5.1 Poređenje silhouette score-ova 7
5.2 Uticaj broja atributa i PCA 7
5.3 Diskusija 7

6 Pravila pridruživanja **8**
6.1 Metodologija 8
6.2 Algoritmi: Apriori i FP-Growth 9
6.3 Rezultati po klasterima 9

7 Zaključak **9**

1 Uvod

Cilj ovog rada je analiza skupa podataka o ekspresiji gena pojedinačnih ćelija ljudske jetre (GSE115469) primenom metoda klasterovanja i pravila pridruživanja. Cilj klasterovanja je grupisanje ćelija na osnovu njihovih ekspresionih profila, gde svaki klaster potencijalno odgovara jednom tipu ćelija prisutnom u jetri. Primenom pravila pridruživanja analiziraju se obrasci ko-ekspresije gena unutar dobijenih klastera, sa ciljem otkrivanja gena koji se zajedno aktiviraju u određenim tipovima ćelija. Rezultati različitih algoritama klasterovanja porede se korišćenjem silhouette koeficijenta, a analizira se i uticaj redukcije dimenzionalnosti i broja atributa na kvalitet klasterovanja.

2 Opis skupa podataka

GSE115469 je javno dostupan single-cell RNA sequencing (scRNA-seq) skup podataka ljudske jetre. Sadrži 8444 ćelija i ekspresiju 20007 gena. Dataset potiče iz istraživanja koje je analiziralo različite tipove ćelija u zdravoj jetri, uključujući hepatocite, endotelne ćelije, Kupfferove ćelije (makrofage jetre), NK ćelije i T ćelije.

scRNA-seq tehnologija meri koliko je svaki gen aktivan (eksprimiran) u svakoj pojedinačnoj ćeliji, što daje ogromnu količinu podataka ali i mnogo šuma i nula. Ova karakteristika poznata je kao *sparsity* (retkost) podataka i posledica je dva faktora:

- **Biološki razlog:** ćelija u datom trenutku aktivno koristi samo mali deo svog genoma.
- **Tehnički razlog (dropout efekat):** scRNA-seq tehnologija ne detektuje sve molekule RNK u ćeliji.

U ovom skupu podataka, prosečno je 727 od 3000 selektovanih gena eksprimirano po ćeliji (oko 24%), što znači da je približno 76% vrednosti jednako nuli.

3 Preprocesiranje podataka

3.1 Selekcija atributa

Od ukupno 20007 gena, zadržano je 3000 gena sa najvećom varijansom ekspresije. Geni sa malom varijansom su skoro uvek nula u svim ćelijama i ne pomažu algoritmu da razlikuje ćelije. Za svaki gen računata je varijansa ekspresije kroz sve ćelije, geni su sortirani po varijanci i zadržano je 3000 sa najvećim vrednostima.

3.2 Standardizacija

Primenjen je `StandardScaler` koji skalira svaki gen na srednju vrednost 0 i standardnu devijaciju 1. Ovo je neophodno jer geni imaju različite opsege ekspresije, a bez skaliranja algoritmi klasterovanja bi davali veći značaj genima sa većim vrednostima samo zbog skale. Napomena: industrijski standard za scRNA-seq podatke je log-normalizacija (`log1p`), ali StandardScaler je dao zadovoljavajuće rezultate u kombinaciji sa PCA.

3.3 Redukcija dimenzionalnosti — PCA

Principal Component Analysis (PCA) je primenjena da se dimenzionalnost smanji sa 3000 na 50 komponenti. 50 PCA komponenti objašnjava 25.7% ukupne varijanse, što je tipično za scRNA-seq podatke zbog njihove visoke dimenzionalnosti i biološke kompleksnosti. Ovo je *sweet spot* između očuvanja informacije i izbegavanja *curse of dimensionality* koji negativno utiče na algoritme klasterovanja zasnovane na euklidskom rastojanju.

3.4 Vizualizacija — UMAP

UMAP (Uniform Manifold Approximation and Projection) je korišćen isključivo za vizualizaciju — algoritam projektuje 50 PCA dimenzija na 2D prostor čuvajući susedske odnose između ćelija. UMAP ne utiče na klasterovanje i služi samo da se vizualno proceni kvalitet rezultata. Isti UMAP prostor korišćen je za vizualizaciju svih algoritama radi direktnog poređenja.

4 Klasterovanje

4.1 Određivanje optimalnog broja klastera

Optimalan broj klastera određen je kombinacijom Elbow metode i Silhouette analize za K-Means algoritam u opsegu $k = 2$ do $k = 14$.

Elbow metoda prati inerciju (SSE — sumu kvadratnih rastojanja do centroida) kako se povećava broj klastera. Kriva kontinualno opada bez jasnog lakta, što je tipično za biološke podatke. Blagi prelom uočava se oko $k = 5$–6.

Silhouette analiza pokazuje lokalne maksimume za $k = 4$ i $k = 5$ (score ≈ 0.31). Uzimajući u obzir obe metrike i činjenicu da jetra ima 5–8 poznatih tipova ćelija, odabrano je $k = 5$ kao optimalan broj klastera.

4.2 K-Means

K-Means algoritam minimizuje sumu kvadratnih rastojanja svih tačaka do centroida njihovog klastera. Centroid predstavlja srednju vrednost svih tačaka u klasteru. Algoritam je pokrenut sa `n_init=10` radi robustnosti na lošu inicijalizaciju.

Tabela 1: Poređenje K-Means konfiguracija

Konfiguracija	Silhouette score
Top3000_PCA	0.3097
Top500_PCA	0.1883
Top1000_PCA	0.1843
Top500_bezPCA	0.1132
Top3000_bezPCA	−0.0005

Pobednički model Top3000_PCA postiže silhouette score 0.3097 sa raspodelom klastera [3480, 1133, 585, 1101, 2145]. Neuniformna raspodela je biološki očekivana — hepatociti su dominantni tip ćelija u jetri (klaster 0, 41.2%).

4.3 Aglomerativno klasterovanje

Aglomerativno klasterovanje gradi hijerarhiju klastera odozdo prema gore, postepeno spajajući najbliže klastere. Testirana su tri načina određivanja rastojanja između klastera.

Tabela 2: Poređenje linkage metoda

Linkage	Raspodela	Silhouette score
ward	[3509, 604, 1094, 1087, 2150]	0.3052
complete	[8440, 1, 1, 1, 1]	N/A (chaining efekat)
average	[8440, 1, 1, 1, 1]	N/A (chaining efekat)

Complete i average linkage pokazuju chaining efekat — gotovo sve ćelije svrstane su u jedan klaster. Ovo je direktna posledica neuniformne gustine scRNA-seq podataka. Ward linkage je jedini pogodan jer njegova strategija minimizacije varijanse funkcioniše dobro u visokodimenzionalnom prostoru.

4.4 Bisecting K-Means

Bisecting K-Means je razdvajajući hijerarhijski algoritam koji počinje sa jednim klasterom koji sadrži sve ćelije i iterativno ga deli na dva podklastera primenom

2-means algoritma. Za razliku od K-Means koji globalno optimizuje sve klastere odjednom, ovaj algoritam deli klastere sekvencijalno, što znači da greška napravljena u ranom deljenju utiče na sve naredne korake.

Tabela 3: Poređenje Bisecting K-Means konfiguracija

Konfiguracija	Silhouette score
Top3000_PCA	0.2805
Top500_PCA	0.1702
Top3000_noPCA	0.0308

4.5 DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) je algoritam zasnovan na gustini koji ne zahteva unapred definisan broj klastera. Tačke podataka klasifikuju se kao tačke u jezgru, granične tačke ili šum na osnovu broja suseda unutar zadatog radijusa `eps`.

K-distance grafik pokazuje da velika većina ćelija (≈8000 od 8444) ima 5. najbližeg suseda na rastojanju manjem od 10, dok samo mali broj tačaka ima velika rastojanja. Odsustvo jasnog lakta direktan je indikator da podaci nemaju prirodnu gustinsku strukturu koju DBSCAN može da iskoristi.

Tabela 4: Rezultati DBSCAN za različite vrednosti eps

eps	Broj klastera	Šum tačke	Šum %
3	0	8444	100.0%
5	14	8115	96.1%
8	5	3454	40.9%
10	3	1754	20.8%
15	3	541	6.4%

Ne postoji vrednost eps koja istovremeno daje pravi broj klastera (≈5) i prihvatljiv procenat šuma (<10%). Odabran je `eps=15` kao najrazumniji kompromis. Silhouette score od 0.3251 (bez šum tačaka) je varljivo visok — jedan dominantni klaster sadrži ≈93% ćelija, što je matematički artefakt, a ne stvarno dobro klasterovanje.

4.6 K-Medoids

K-Medoids je varijanta K-Means gde su predstavnici klastera stvarne tačke iz dataseta (medoidi), a ne virtuelni centroidi. Ovo ga čini robusnijim na autlajere, ali

ograničenim u kvalitetu reprezentacije klastera kada su klasteri blizu jedni drugima.

Tabela 5: Poređenje K-Medoids konfiguracija

Konfiguracija	Silhouette score
Top500_PCA	0.2156
Top3000_PCA	0.1622
Top3000_noPCA	−0.0289

Jedini algoritam gde manji broj gena (Top500_PCA) daje bolji rezultat od većeg (Top3000_PCA). Ovo je karakteristično za K-Medoids — sa manjim brojem dimenzija lakše pronalazi stabilne medoide koji dobro reprezentuju klastere.

5 Poređenje algoritama

5.1 Poređenje silhouette score-ova

Tabela 6: Poređenje svih algoritama

Algoritam	Konfiguracija	Silhouette score
K-Means	Top3000_PCA	0.3097
Agglomerative (ward)	Top3000_PCA	0.3052
DBSCAN*	eps=15	0.3251
Bisecting K-Means	Top3000_PCA	0.2805
K-Medoids	Top500_PCA	0.2156
K-Medoids	Top3000_PCA	0.1622

* DBSCAN score je varljiv zbog dominacije jednog klastera sa 93% ćelija.

5.2 Uticaj broja atributa i PCA

Najvažniji zaključak je da je PCA redukcija dimenzionalnosti presudna. Bez PCA, svi algoritmi daju loše ili negativne silhouette score-ove. Više gena uz PCA daje bolje rezultate, osim kod K-Medoids gde je obrnuto.

5.3 Diskusija

K-Means se pokazao kao najbolji algoritam za ovaj dataset. Globalna optimizacija centroida funkcioniše dobro kada su klasteri relativno sferični i ujednačeni, što je

Tabela 7: Silhouette score po konfiguracijama i algoritmima

Konfiguracija	K-Means	Bisecting K-Means	K-Medoids
Top3000_PCA	0.3097	0.2805	0.1622
Top1000_PCA	0.1843	—	—
Top500_PCA	0.1883	0.1702	0.2156
Top3000_bezPCA	−0.0005	0.0308	−0.0289
Top500_bezPCA	0.1132	—	—

slučaj sa scRNA-seq podacima nakon PCA.

Aglomerativno klasterovanje (ward) postiglo je skoro identičan score kao K-Means (0.3052 vs 0.3097), što potvrđuje robustnost pronađenih klastera — dva potpuno različita algoritma pronalaze istu strukturu u podacima.

Bisecting K-Means je konzistentno nešto slabiji od K-Means u svim konfiguracijama jer sekvencijalno deljenje nije globalno optimalno.

DBSCAN je fundamentalno nepogodan za ovaj tip podataka zbog uniformne gustine u PCA prostoru i *curse of dimensionality*. Odsustvo jasnog lakta na K-distance grafikonu to vizualno potvrđuje.

K-Medoids je nestabilan i jedini algoritam gde Top500_PCA daje bolji rezultat od Top3000_PCA, što sugeriše da je ograničenje na stvarne tačke problematično u višim dimenzijama.

6 Pravila pridruživanja

6.1 Metodologija

Pravila pridruživanja primenjena su po klasterima K-Means algoritma ($k = 5$). Za svaki klaster posebno pronalažena su pravila ko-ekspresije gena oblika: ako je gen A eksprimiran u ćeliji, tada je gen B takođe eksprimiran. Ovaj pristup daje pravila specifična za svaki tip ćelija.

Zbog memorijskih ograničenja, analiza je izvršena na 12 gena sa najvećom varijansom. Binarizacija ekspresije je urađena pragom > 0 na originalnim podacima (gen je eksprimiran ako je detektovan). Parametri: `min_support = 0.7`, `min_confidence = 0.8`.

6.2 Algoritmi: Apriori i FP-Growth

Apriori generiše sve moguće kombinacije kandidata i filtrira ih po support pragu — eksponencijalno spor ali jednostavan. FP-Growth gradi kompaktnu FP-Tree strukturu u memoriji i direktno pronalazi česte skupove bez generisanja kandidata.

Tabela 8: Poređenje Apriori i FP-Growth

Klaster	Čestih skupova	Pravila	Apriori (s)	FP-Growth (s)
0	4095	523250	0.760	62.226
1	39	101	0.008	0.172
2	39	104	0.008	0.106
3	41	127	0.008	0.178
4	37	121	0.009	0.323

Apriori se pokazao bržim od FP-Growth na ovom datasetu. FP-Growth gradi FP-Tree strukturu koja ima overhead pri malom broju stavki (12 gena) — prednost FP-Growth dolazi do izražaja tek sa velikim brojem stavki. Oba algoritma daju identične rezultate.

6.3 Rezultati po klasterima

Klaster 0 (3480 ćelija) generisao je 523250 pravila jer su svi geni eksprimirani u ≈97% ćelija uz lift vrednosti oko 1.001, što znači da su geni praktično nezavisni. Ovo je karakteristika hepatocita koji masivno eksprimiraju sve analizirane gene.

Klasteri 1–4 daju razuman broj pravila (100–127) sa lift vrednostima 1.02–1.05, što pokazuje blagu ali stvarnu asocijaciju između gena. Geni koji se pojavljuju u pravilima su poznati jetreni geni: ALB (albumin), SAA1/SAA2 (serum amyloid A), SERPINA1 (alfa-1 antitripsin), HP (haptoglobin), APOA1/APOA2/APOC1/APOC3 (apolipoproteini), FGA (fibrinogen) i ORM1 (orosomukoid).

Prisustvo isključivo jetrenih gena u svim pravilima potvrđuje validnost klasterovanja.

7 Zaključak

U ovom radu analiziran je scRNA-seq dataset ljudske jetre GSE115469 primenom pet algoritama klasterovanja i dva algoritma za pravila pridruživanja. Ključni zaključci su:

Tabela 9: Top pravila iz klastera 1

Antecedent	Consequent	Support	Confidence	Lift
{SAA2}	{SERPINA1, SAA1}	0.7546	0.9243	1.0483
{SERPINA1, SAA1}	{SAA2}	0.7546	0.8559	1.0483
{HP, SAA1}	{SAA2}	0.7123	0.8450	1.0350
{SAA2}	{HP, SAA1}	0.7123	0.8724	1.0350

- PCA redukcija dimenzionalnosti je presudna za kvalitet klasterovanja. Bez PCA, svi algoritmi daju loše rezultate (silhouette score oko 0 ili negativan).
- K-Means sa konfiguracijom Top3000_PCA je pobednički algoritam sa silhouette score-om 0.3097.
- Aglomerativno klasterovanje (ward linkage) daje skoro identične rezultate kao K-Means (0.3052), što potvrđuje robustnost pronađene strukture.
- DBSCAN nije pogodan za scRNA-seq podatke zbog uniformne gustine u PCA prostoru.
- K-Medoids preferira manje dimenzije — Top500_PCA daje bolji score (0.2156) od Top3000_PCA (0.1622).
- Pravila pridruživanja po klasterima otkrila su biološke obrasce ko-ekspresije jetrenih gena, što potvrđuje validnost klasterovanja.
- Apriori se pokazao bržim od FP-Growth na ovom datasetu sa 12 gena zbog overhead-a FP-Tree strukture pri malom broju stavki.

Ograničenje: analiza pravila pridruživanja izvršena je na samo 12 gena zbog memorijskih ograničenja. Sa više resursa i većim brojem gena, pravila bi bila bogatija i potencijalno otkrivala specifičnije obrasce po tipovima ćelija.